浙江大学

Data Structure & Database Technique
Project3
Project Report

2020~2021 春夏学期 2021 年 3 月 31 日

Categories

Project3

Chapter 1: Introduction

Background and Our goals :

散列表（Hash table，也叫哈希表），是根据关键码值(Key value)而直接进行访问的数据结构。也就是说，它通过把关键码值映射到表中一个位置来访问记录，以加快查找的速度。这个映射函数叫做散列函数，存放记录的数组叫做散列表。

给定表 M，存在函数 f(key)，对任意给定的关键字值 key，代入函数后若能得到包含该关键字的记录在表中的地址，则称表 M 为哈希(Hash）表，函数 f(key)为哈希(Hash) 函数。

实现散列表，要求：

清晰的注释

具有再散列功能

能够处理冲突

具有性能相关的测试

java 中的 hashmap，当数据数量达到阈值的时候(0.75)，就会发生 rehash，hash 表长度变为原来的二倍，将原 hash 表数据全部重新计算 hash 地址，重新分配位置，达到 rehash 目的.

hash table 的大小是素数时碰撞的概率小（有证明）。若直接扩大为两倍反而可能性能恶化。另外随着 size 变大，素数的密度会下降得足够小，也不至于反复扩容。

Chapter 2: Algorithm Specification

我们处理冲突,就是采用开放地址, 解决冲突,尝试_pos, _pos+1, _pos+2...

. 开放寻址法：Hi=(H(key) + di) MOD m,i=1,2，…，k(k<=m-1），其中 H(key）为散列函数，m 为散列表长，di 为增量序列，可有下列三种取法：

1.1. di=1,2,3，…，m-1，称线性探测再散列；

1.2. di=1^2,-1^2,2^2,-2^2，⑶^2，…，±（k)^2,(k<=m/2）称二次探测再散列；

1.3. di=伪随机数序列，称伪随机探测再散列。

取关键字或关键字的某个线性函数值为散列地址。即 H(key)=key 或 H(key) = a key + b，其中 a 和 b 为常数。若其中 H(key）中已经有值了，就往下一个找，直到 H(key）中没有值了，就放进去。

我们桶个数<最大条目数/最大装载因子就扩容到一个素数，并进行一次 rehash。

再散列, 就是 reload factor >0.7 时重新散列, 用公式 nextprime 计算 hashtable 的下一个容量, 变大到下一个数,遍历 hashTable，备份所有有效的元素, 用公式 nextprime 计算 hashtable 的下一个容量,capacity 变大到公式计算出的值,然后将之前所有的元素逐一插入.

Chapter 3: Testing Results

```
insert Entry(1,11)...
capacity=3,size=1
key=1,value=11
insert Entry(2,22)...
capacity=3,size=2
key=1,value=11
key=2,value=22
insert Entry(3,33)...
capacity=3,size=3
key=3,value=33
key=1,value=11
key=2,value=22
insert Entry(4,44)...
capacity=41,size=4
key=1,value=101
key=2,value=22
key=3,value=33
key=4,value=44
runtime:    0.002
```

Rehash+ insert 4,44 = 2ms

插入 4 个 rehash 一次 runtime: 0.008s , 8ms

插入 9 个, 9ms

```
3       cout << "insert Entry(3,33)..." << endl;
4       pTable->insert(Entry(3,33));
5       pTable->display();
6       cout << "insert Entry(4,44)...
7       pTable->insert(Entry(4,44));
8       (*pTable)[1]->_value = 101;
9       pTable->display();
0   pTable->insert(Entry(5,55));
1   pTable->insert(Entry(6,66));
2   pTable->insert(Entry(7,77));
3   pTable->insert(Entry(8,88));
4   pTable->insert(Entry(9,99));
```

```
D:\curriculum_design to git\curricul
key=1,value=11
key=2,value=22
insert Entry(3,33)...
capacity=3,size=3
key=3,value=33
key=1,value=11
key=2,value=22
insert Entry(4,44)...
capacity=41,size=4
key=1,value=101
key=2,value=22
key=3,value=33
key=4,value=44
runtime:    0.009
```

插入 28 个, 9ms

```
tbench.cpp [*] autobuild.cpp
pTable->insert(Entry(24,264));
pTable->insert(Entry(25,275));
pTable->insert(Entry(26,286));
pTable->insert(Entry(27,297));
pTable->insert(Entry(28,308));
    end=clock();
    ret=double(end-begin)/CLOCKS_PER_SEC;
    cout<<"runtime:   "<<ret<<endl;
    cout << endl << "delete Entry(1,11)..." << e
    pTable->remove(Entry(1,11));
    pTable->display();
    cout << "delete Entry(2,22)..." << endl;
    pTable->remove(Entry(2,22));
    pTable->display();
编译日志 调试 搜索结果 关闭
```

```
D:\curriculum_design to git\curriculum
insert Entry(1,11)...
capacity=3,size=1
key=1,value=11
insert Entry(2,22)...
capacity=3,size=2
key=1,value=11
key=2,value=22
insert Entry(3,33)...
capacity=3,size=3
key=1,value=11
key=2,value=22
key=3,value=33
insert Entry(4,44)...
capacity=41,size=4
key=1,value=101
key=2,value=22
key=3,value=33
key=4,value=44
runtime:   0.009
```

```
key=2,value=22
insert Entry(3,33)...
capacity=3,size=3
key=3,value=33
key=1,value=11
key=2,value=22
insert Entry(4,44)...
capacity=41,size=4
key=1,value=101
key=2,value=22
key=3,value=33
key=4,value=44

delete Entry(1,11)...
capacity=41,size=3
key=2,value=22
key=3,value=33
key=4,value=44
delete Entry(2,22)...
capacity=41,size=2
key=3,value=33
key=4,value=44
delete Entry(3,33)...
capacity=41,size=1
key=4,value=44
delete Entry(3,33)...
capacity=41,size=1
key=4,value=44
runtime:   0.017
```

插入 4 个，删除 3 个,17ms
执行一百次空的 remove, 10ms

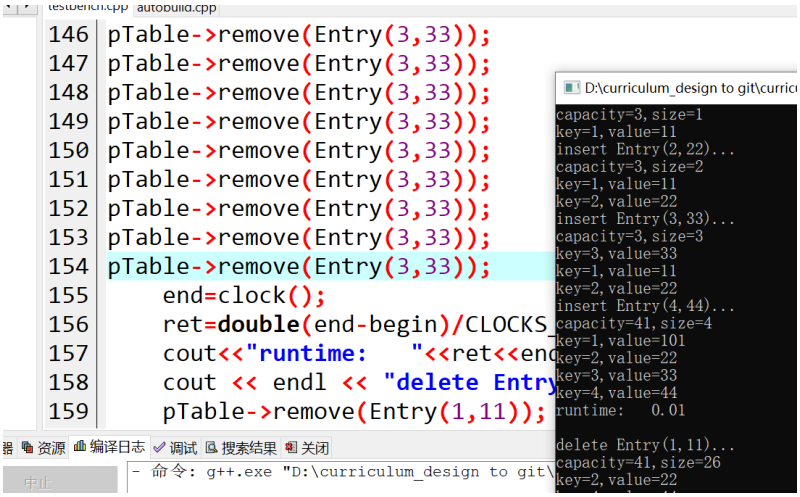

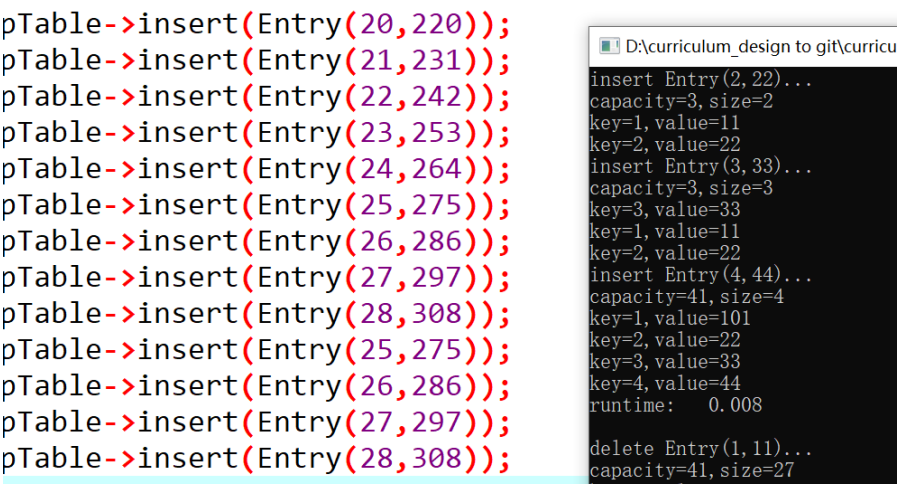

100 次空的 insert, 8ms.

Chapter 4: Analysis and Comments

time complexities are O(1) because use hash function to insert.
第一步：key.hashfunction()，时间复杂度 O(1)。
第二步：找到桶以后，判断桶里是否有元素，如果没有，直接 new 一个 entey 节点插入到数组中。时间复杂度 O(1)。

space complexities of the algorithms
All space complexities are O(n) ,rehash function needs to store all old values in the vector.

未来期待的改进:
优化_pos 函数，减少_pos 私有变量的耦合,现在在各个函数中耦合比较严重.

出现的问题:

问题 1 我写了 100 个插入的测试,但是没有输出,

```
cout<<"runtime:      "<<ret<<endl;
pTable->display();
```

都没东西,为什么?

排查方法: 我把 99 个注释了, 正常输出.

36 个就不行, 不知道为啥. 21 个也是可以的.29 个也可以, 30 个就不行.

3221225477 (0xC0000005): 访问越界, 一般是读或写了野指针指向的内存

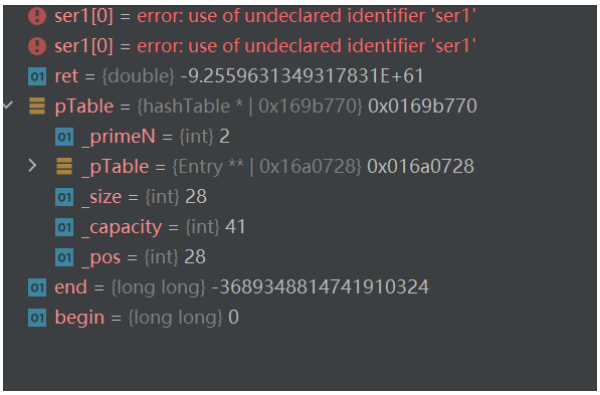

41*0.7 = 28.7 所以 29 个会出错. 下一步变成了 43

```
int hashTable::hashFunction(const KeyType& key) {//一种简单的哈希函数 ,

为了未来改进封装一下.

    return key%_capacity;
}
```

我怀疑是这里 key 没有取值,是一个地址

我一开始用的是

```
find(const KeyType& key){
```

中修改 pos , 然后后面直接用这个 pos 插入.

```
_pos = (_pos+i)%_capacity;
…

_pTable[_pos] = new Entry(e);//当前位置插入 e
```

我觉得可能 return 一个下标更好?

Indirection requires pointer operand ('KeyType' (aka 'int') invalid

解决方法:

问题 2 Process finished with exit code -1073741819 (0xC0000005)

问题 3 函数。。。。已有主体”。
应该先在头文件中声明函数，然后在.cpp 中实现，这样调用函数时才不会提示说“函数。。。。已有主体”。

我就是多复制了一遍，然后 test.cpp 应该

```
#include "hashtable.hpp"
```

而不是 include cpp 文件

问题 4 Exception 0xc0000005 encountered at address 0x961d54: Access violation reading location 0xcdcdcdcd
ptr 是一个指点，但你似乎从来没有初始化它。换句话说，没有指向任何东西。

当您尝试使用此指针时，你得到未定义的行为。你实际上很幸运，应用程序崩溃，因为任何其他可能发生。它本来可以似乎工作。要直接解决此问题，您需要初始化.

Key 为什么会没有东西呢?

在这里是正确的

Rehash 后 e 没有了,为什么?

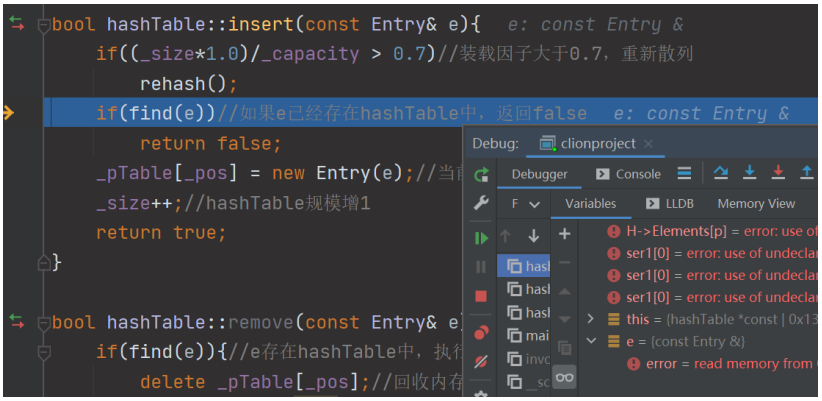

我明白了,

```
for(int i = 0; i < sizeOld; i++)//将之前所有的元素逐一插入
    insert(*pTableOld[i]);
```

这里会逐个插入,调用 insert，第一个会是一个空指针传入 insert.

```
pTableOld[i] = new Entry(*_pTable[i]);
```

没有存进去，为啥?

那 4 为啥不会出 bug? 4 的第一个是 3,33 传入 insert 没有出错,但是其实应该是第一个 1,11, .

第二个是 1,11,第三个是 2,22，然后 I =3 ,sizeold = 3

为什么第一个是 3,33?

然后 30 插入的时候,需要 rehash

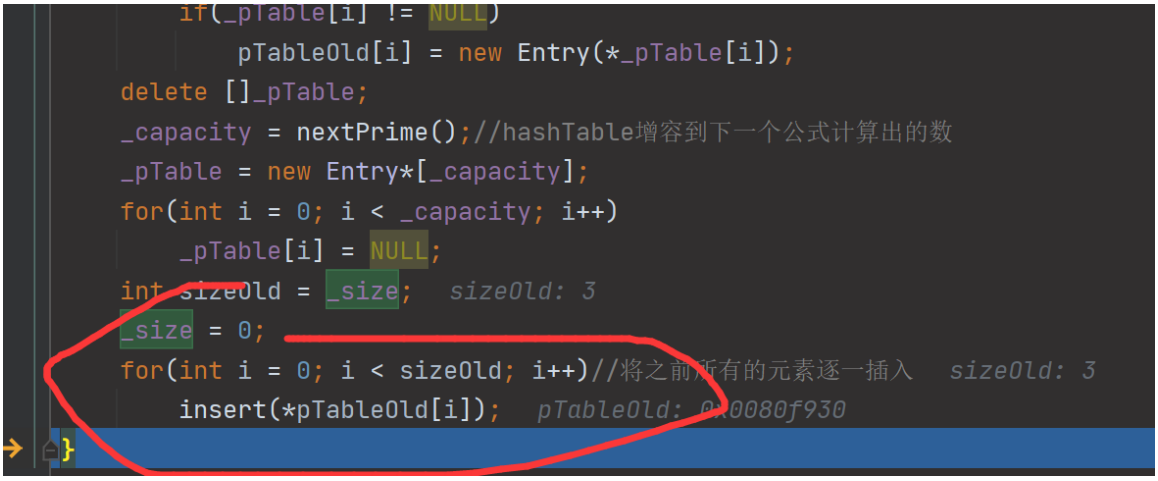

在备份后，插回去就报错了

```
for(int i = 0; i < _capacity; i++)//遍历 hashTable， 备份所有有效的元素
    if(_pTable[i] != NULL)
        pTableOld[i] = new Entry(*_pTable[i]);
```

这里没有备份进去,但是我不知道为什么.